Sesame 机器人行走实验报告（简版）

上海交通大学强化学习课程作业 • PDF 导出：2026-11-09

- 1. 代码结构与使用方法
- 2. 奖励函数设计
- 3. 已完成的 Demo、测评指标与结果
- 4. 待改进的地方与对应方法

更新：2026-11-09；目录：`/home/ywwang/sesame`。任务是在平地沿世界 `+X` 方向以 0.10 m/s 行走。基线方法为 **PPO、SAC、DQN**，并保留 **Dyna-PPO** 已有结果。PPO 只展示奖励改进后的结果；域随机化作为已尝试的改进方法。课程统一评分和真机部署尚未接入。

1. 代码结构与使用方法

代码入口

文件或目录	用途
`assets/`	机器人源模型、Isaac USD 和网格
environment.py	基础观测、动作、奖励和终止条件
dr_environment.py	物理参数、时延和初态随机化
study_environment.py	时延消融及评估指标
heading_environment.py	新增绝对航向奖励
train_heading_ppo.py	当前 PPO 训练入口，已加入航向奖励
offpolicy.py、train_offpolicy.py	SAC、DQN 算法与训练入口
dyna_ppo.py、dyna_world_model.py	Dyna-PPO 算法与动力学/奖励模型
train_dyna_ppo.py	已有 Dyna-PPO 训练入口，仍使用旧奖励
evaluate_offpolicy.py、analyze_offpolicy.py	PPO、SAC、DQN 的共同评估、统计和曲线
evaluate_dyna_ppo.py、analyze_dyna_ppo.py	Dyna-PPO 评估与报告入口
record_offpolicy_video.py	PPO、SAC、DQN 的单模型录像
`runs/`、`docs/`、`reports/`	实验结果、说明文档、验证记录

模型权重

下表直接链接到清理后保留的 **12 个最终模型**；各列对应训练随机种子，均为 `final.pt`。模型与本报告的结果和 Demo 对应，训练目录同时保留配置、日志和源码快照。

方法	种子 42	种子 43	种子 44
PPO	final.pt	final.pt	final.pt
SAC	final.pt	final.pt	final.pt
DQN	final.pt	final.pt	final.pt
Dyna-PPO	final.pt	final.pt	final.pt

PPO、SAC、DQN 使用共同的改进奖励，对应评估配置中的 9 个模型；Dyna-PPO 使用旧奖励，其结果单独列出。2026-11-08 已删除其余旧权重、中间检查点和测试模型，历史结果与视频仍保留，详见清理记录。

接口要点：36 维观测包括机身速度、角速度、重力方向、速度指令、8 个关节位置/速度及上一动作。8 维动作按 `[R1,R2,L1,L2,R4,R3,L3,L4]` 排列，经 裁剪→q_stand+0.58a→限位/限速→域随机化中的时延/滞后 执行。控制频率 50 Hz，回合最长 10 秒。PPO、Dyna-PPO 加载时保留模型中的观测归一化参数；SAC、DQN 使用环境已有的固定观测缩放。

初始化环境

在同一个 Bash 终端先执行下面的代码。训练、推理和仿真必须使用 CUDA；新实验使用新目录，保留冻结源码、协议和历史结果，不执行 Git 操作。

```
cd /home/ywwang/sesame
nvidia-smi
isaac_py() {
  CONDA_NO_PLUGINS=true PYTHONDONTWRITEBYTECODE=1 PYTHONNOUSERSITE=1 \
  /home/ubuntu/miniforge3/bin/conda run -n env_isaaclab --no-capture-output \
  /home/ubuntu/miniforge3/envs/env_isaaclab/bin/python "$@"
}
```

训练当前版本

```
SESAME_TRAIN_DIR="$(mktemp -d /home/ywwang/sesame/runs/heading_retrain_XXXXXX)"
isaac_py -u scripts/train_heading_ppo.py \
  --seed 42 --num-envs 256 --iterations 250 --steps-per-env 32 \
  --heading-penalty-scale 0.5 --run-dir "$SESAME_TRAIN_DIR"
```

每个随机种子训练 204.8 万步。三个随机种子分别使用 42、43、44，并各用新目录。正式入口固定上述预算；短测需加 `--smoke`，例如改为 16 环境、20 次更新。成功后检查 `result.json` 中的 `status=completed` 和 `reload_max_abs_action_error=0`。

SAC 使用同一奖励和域随机化设置：

```
SESAME_SAC_RUN="$(mktemp -d /home/ywwang/sesame/runs/sac_retrain_XXXXXX)"
isaac_py -u scripts/train_offpolicy.py --algorithm sac --seed 42 --run-dir "$SESAME_SAC_RUN"
```

DQN 将 `--algorithm sac` 改为 `--algorithm dqn`，并使用新目录。两者每个随机种子同样训练 204.8 万步；参数见 SAC、DQN 实验说明。

复评现有模型并生成报告

```
SESAME_EVAL_STUDY="$(mktemp -d /home/ywwang/sesame/runs/algorithms_reeval_XXXXXX)"
cp runs/offpolicy_heading_20261107/evaluation_protocol.json "$SESAME_EVAL_STUDY/evaluation_protocol.json"
cp runs/offpolicy_heading_20261107/evaluation_protocol.sha256 "$SESAME_EVAL_STUDY/
evaluation_protocol.sha256"
isaac_py -u scripts/evaluate_offpolicy.py \
  --protocol "$SESAME_EVAL_STUDY/evaluation_protocol.json" \
  --output-dir "$SESAME_EVAL_STUDY/evaluation"

PYTHONNOUSERSITE=1 PYTHONDONTWRITEBYTECODE=1 \
  /home/ubuntu/miniforge3/envs/metaworld_v010/bin/python -s \
  scripts/analyze_offpolicy.py "$SESAME_EVAL_STUDY"
```

此命令复评配置中**已有的九个 PPO、SAC、DQN 最终模型**。Dyna-PPO 的历史完整对比配置还引用已删除的旧 PPO 权重，不能直接重跑。新训练结果须建立新评估配置并更新模型路径/哈希，不会自动纳入复评。报告输出到新目录的 `analysis/`；绘图只读取保存的数据，可使用 CPU。

重新录像

```
SESAME_VIDEO_DIR="$(mktemp -d /home/ywwang/sesame/runs/algorithm_video_XXXXXX)"
isaac_py -u scripts/record_offpolicy_video.py \
  --protocol runs/offpolicy_heading_20261107/evaluation_protocol.json \
  --policy-id ppo_seed42 \
  --output-dir "$SESAME_VIDEO_DIR"
```

此命令录制 PPO；将 `--policy-id` 改为 `sac_seed42` 或 `dqn_seed42` 可录制对应方法，每次使用新目录。录像使用 `evaluation_protocol.json`，固定训练种子 42、测试种子 25042；首次渲染可能需要几分钟初始化。

Dyna-PPO 的配置与实现见 Dyna-PPO 说明。文档中的目录是历史结果，重跑时须换成新目录。

2. 奖励函数设计

下表为 **PPO、SAC、DQN 共同使用的改进后奖励**。`v` 为**世界系线速度**，`ω` 为**机身系角速度**；`u=clip(-projected_gravity_b.z,0,1)` 为直立程度；`a` 为裁剪后的归一化动作；`mean` 对 8 个关节取平均。下表均为奖励率。

奖励项	当前公式
平面速度跟踪	`1.5 × exp(-((vx-0.10)²+vy²)/0.01) × u²`
向前运动	`clip(vx/0.10,-1,1) × u²`
直立	`+0.35 × u`
横向速度	`-0.10 × (vy/0.10)²`
偏航角速度	`-0.03 × ωz²`
横滚/俯仰角速度	`-0.01 × (ωx²+ωy²)`
垂直速度	`-0.02 × (vz/0.10)²`
力矩	`-0.02 × mean((τ/0.18)²)`
相邻动作差	`-0.08 × mean((a_t-a_(t-1))²)`
偏离站姿	`-0.10 × mean((q-q_stand)²)`
新增航向项	`-0.5 × (1-cos(ψ-ψ_cmd))`，当前目标航向 `ψ_cmd=0`

单步奖励 = `0.02 × 奖励率总和 − 2 × I(真正终止)`。 跌倒、越界或无效状态扣终止惩罚，正常超时不扣。偏航 90° 时新增单步惩罚为 `-0.01`；零平面指令时关闭航向项。

航向项针对“机身侧着朝目标方向走”的问题；原偏航角速度惩罚只能限制转动。动作差约束的是裁剪动作，不是实际关节加速度；力矩为仿真估计，不能当作实测能耗。滑脚、腾空、异常接触、软限位和关节加速度奖励目前尚未加入。

3. 已完成的 Demo、测评指标与结果

基线方法

方法	实现与动作
PPO	普通 PPO；8 维连续动作，使用改进后的奖励
SAC	双 Q 网络、随机策略和自动温度调节；8 维连续动作，使用相同奖励
DQN	分支网络和 Double DQN 更新；每个关节离散为 `[-1,-0.5,0,0.5,1]`，使用相同奖励

DQN 的动作空间经过离散化，与 PPO、SAC 的连续动作不同；正文统一称为 DQN。三种方法均使用完整域随机化，每个随机种子训练 **204.8 万步**。PPO 复用奖励改进后的最终模型，SAC、DQN 从头训练；网络、观测归一化和更新次数不同，计算量不等同。

测评指标

主指标是**前向速度误差**，同时检查航向、侧移、跌倒和平滑性。RMSE 表示均方根误差，RMS 表示均方根。下表的 `mean` 对该回合的采样点取平均。

指标	计算方法	单位与判断
前向速度误差（RMSE）	`√mean((vx−0.10)²)`	m/s，越低越好
平面速度误差（RMSE）	`√mean((vx−0.10)²+vy²)`	m/s，越低越好
航向误差（RMS）	整个回合相对世界 +X 的角度误差均方根；角差折回 `[-π,π]` 后计算并换算为度	°，越低越好
终点偏航	回合终点航向角误差的绝对值	°，越低越好，与整个回合的航向误差不同
终点侧移	`abs(y末−y初)`	m 或 cm，越低越好
前向位移	`x末−x初`	m，10 秒目标约 1 m，并非越远越好
跌倒率	跌倒回合数 ÷ 总回合数	%，越低越好
关节目标加速度（RMS）	实际执行的关节目标位置二阶差分：`(q*_t−2q*_(t−1)+q*_(t−2))/Δt²`，再取 RMS	rad/s²，结合速度和位移判断平滑性
实际关节加速度（RMS）	仿真关节速度一阶差分：`(q̇_t−q̇_(t−1))/Δt`，再取 RMS	rad/s²，结合速度和位移判断平滑性

`vx`、`vy` 为世界坐标系速度。`q*` 是经过动作裁剪、关节约束及时延/滞后处理后的关节目标位置；加速度按 **50 Hz（Δt=0.02 s）**采样，对时间和 8 个关节取均方根，排除重置跳变。这两项用于观察抖动程度，不是抖动频率或物理瞬时峰值；不能用不走路换取较低加速度。

跌倒判定为机身高度低于 **0.023 m**，或直立度低于 **0.5**（约整体倾斜超过 60°）。越界和无效状态另行记录，不自动计入跌倒。辅助记录关节目标变化率、动作裁剪比例、总回报和回合时长。

测试设置

分别在**标准参数**和**随机参数**下测试；随机参数来自训练时的域随机化范围。使用训练种子 42/43/44、测试种子 25042/26042，每个测试种子取前 64 个环境的首回合：每模型每条件 **128 回合**，每方法每条件 **384 回合**，三种方法共 **2304 回合**。每回合最长 10 秒，使用确定性动作，并保证各方法的初态和实际物理参数相同。

先计算每回合指标，再求每模型的 128 回合均值，最后报告 **3 个训练种子的均值 ± 样本标准差**。表中 PPO 为改进奖励后的模型在本次共同测试场景中的结果。

PPO、SAC、DQN 结果

条件	方法	前向速度误差 RMSE（m/s）	航向误差 RMS（°）	终点侧移（cm）	前向位移（m）
标准参数	PPO	0.06570 ± 0.00259	6.68 ± 1.50	13.04 ± 9.45	1.357 ± 0.012
标准参数	SAC	0.04661 ± 0.00543	8.58 ± 0.70	5.00 ± 0.85	1.139 ± 0.162
标准参数	DQN	0.07526 ± 0.00175	14.76 ± 3.31	11.84 ± 5.35	1.177 ± 0.140
随机参数	PPO	0.03610 ± 0.00129	4.80 ± 0.09	3.73 ± 0.66	1.187 ± 0.036
随机参数	SAC	0.04399 ± 0.00137	6.55 ± 0.97	2.85 ± 0.43	1.089 ± 0.026
随机参数	DQN	0.06102 ± 0.00462	14.87 ± 4.06	13.04 ± 2.17	0.969 ± 0.095

条件	方法	关节目标加速度 RMS（rad/s²）	实际关节加速度 RMS（rad/s²）
标准参数	PPO	479.74 ± 20.59	500.74 ± 14.74
标准参数	SAC	532.16 ± 23.20	499.05 ± 30.46
标准参数	DQN	485.57 ± 49.87	511.11 ± 37.96
随机参数	PPO	136.35 ± 7.88	284.21 ± 11.08
随机参数	SAC	135.73 ± 1.68	302.09 ± 3.89
随机参数	DQN	128.31 ± 4.21	305.33 ± 34.06

三种方法在每种条件的 384 回合中均为 **0 次跌倒**，全部完成 10 秒。SAC 的标准参数速度误差比 PPO 低约 **29%**；随机参数下，PPO 的速度和航向误差最低，SAC 的侧移最小。DQN 已能前进，但速度和航向误差较大。加速度指标没有显示 SAC 或 DQN 全面改善平滑性，需同时看行走效果。

数据来源：本次完整结果。指标对照图 · 训练曲线。

Dyna-PPO 已有结果

Dyna-PPO 在 PPO 上增加动力学/奖励模型和单步模型预测更新。已有实验使用**旧奖励**和测试种子 **3042/4042**，因此单独保留，不能与上表直接判断算法优劣。每模型每条件同样评估 128 回合，表中为 3 个训练种子的均值 ± 样本标准差；每条件跌倒 0/384。其统计只提供终点偏航，不能替代整个回合的航向 RMS。

条件	方法	前向速度误差 RMSE（m/s）	终点偏航（°）	终点侧移（cm）	关节目标加速度 RMS（rad/s²）
标准参数	Dyna-PPO	0.06173 ± 0.01135	26.06 ± 34.04	9.22 ± 6.40	371.16 ± 77.36
随机参数	Dyna-PPO	0.04226 ± 0.00573	28.45 ± 34.73	7.73 ± 4.30	112.99 ± 26.27

数据来源：Dyna-PPO 统计。

已有方法的训练时间

均在 **NVIDIA GeForce RTX 4090 D** 上使用 256 个并行环境，每个种子训练 **204.8 万步**。下表为种子 42/43/44 的均值 ± 样本标准差；分钟列便于阅读。

方法	日志记录的训练阶段（秒）	平均约（分钟）	训练程序总时间（秒）
PPO	327.00 ± 0.46	5.45	334.51 ± 1.64
SAC	207.43 ± 2.12	3.46	212.27 ± 2.63
DQN	170.88 ± 0.64	2.85	175.35 ± 0.68
Dyna-PPO（旧奖励）	251.99 ± 0.08	4.20	257.90 ± 0.24

PPO、Dyna-PPO 的训练阶段时间为 `training.jsonl` 中采样与更新计时之和；SAC、DQN 使用 `result.json` 的 `training_wall_seconds`，包含训练循环内的诊断、日志和保存开销，两者计时范围不完全相同。程序总时间统一取 `wall_seconds_before_shutdown`，包含初始化、训练、最终保存和重载验证，不含退出、单独评估和录像。

这些是已有运行的耗时记录，受实现、诊断开销和运行时负载影响，不能直接当成算法的严格加速比。Dyna-PPO 使用旧奖励，不能据此认定它比当前 PPO 更快且效果相同。逐种子数值、计时定义和原始日志路径见训练时间记录。

Demo 视频

方法	视频
PPO	10 秒 Demo
SAC	10 秒 Demo
DQN	10 秒 Demo
Dyna-PPO	已有 Demo

PPO、SAC、DQN 视频固定训练种子 42、测试种子 25042，实际初态和物理参数相同；Dyna-PPO 使用旧测试种子 3042。视频是单回合展示，效果结论以上述多回合统计为准。

4. 待改进的地方与对应方法

已尝试：域随机化（Domain Randomization）

针对固定仿真参数下学到的策略可能难以适应摩擦、质量和执行器变化的问题，在训练回合重置时随机采样物理参数、执行时延和初态。**已实现并用于 PPO、SAC、DQN 和已有 Dyna-PPO 的训练**，作为鲁棒性改进尝试，不单列算法。

当前范围：有效接触摩擦 0.6–1.2；质量/惯量、PD 增益为标准值的 0.8–1.2 倍；力矩/速度上限为 0.8–1.0 倍；执行滞后 0.02–0.06 秒、时延 0–2 个控制步；初始关节扰动 ±0.035 rad、偏航 ±5°、平面速度 ±0.02 m/s。观测噪声未启用。

目标是减小物理参数变化时的性能退化。本表没有同奖励下开关 DR 的对照，不能单独归因 DR 的收益。后续可固定 PPO、奖励与训练预算，只改变 DR 开关/范围，在相同的标准参数和随机参数测试样本上验证。

以下三个方向为**后续实验计划**，尚未完成验证。以当前改进奖励后的 PPO 为主要基线，每轮只改变一个关键因素，保留三个训练种子以及标准参数、随机参数两种测试条件。

1. 减少动作抖动，提升平滑性

分别尝试调整相邻动作差惩罚、增加归一化关节目标加速度惩罚，或对动作使用低通滤波，并逐项对照。主要观察**关节目标加速度 RMS 和实际关节加速度 RMS**是否降低，同时检查前向速度误差、航向误差和前向位移，避免用减速或停止行走换取较低的抖动指标。滤波还需检查是否因响应变慢而影响跟踪。

2. 在较高前进速度下保持不摔倒、不偏航

将当前固定 **0.10 m/s** 的训练扩展为多个速度指令，同步让速度跟踪和前进奖励使用实际指令；拟先测试 **0.10、0.15、0.20 m/s**，这些是候选值，不代表已经实现。比较直接训练目标速度与从低速逐步提高速度的训练方式，保留航向约束、域随机化和原有动作/力矩限制。分别统计每个速度下的**跌倒率、航向误差、速度误差、侧移和成功率**，找出能够稳定直行的速度范围。

3. 减少训练时间，同时保持或提高成功率

分别调整并行环境数、训练批量大小或每轮更新次数，比较**相同训练时间下的成功率**以及**达到同一成功率所需的时间**。可先设置 1、2、3、5 分钟的训练预算，在相同 GPU、奖励、测试场景和计时范围下对照，同时记录真实环境交互步数；评估用时单独记录。SAC、DQN 可作为已有算法对照；Dyna-PPO 需先改为相同奖励后重新训练。当前耗时表只回答已有训练用了多久，尚不能证明缩短时间后仍保持相同成功率。

这里的**成功率 = 满足全部成功条件的回合数 ÷ 总评估回合数**。后续实验的成功条件为：完整行走 10 秒、未跌倒或越界、状态有效，并且速度误差与航向误差均低于预先确定的阈值。阈值在开发阶段确定后固定，各方法使用相同规则；测试失败回合也计入分母。现有结果只确认完整走完 10 秒且未跌倒，尚未统计这一定义下的成功率，不能直接写成 100%。该成功率用于本地实验诊断，课程正式评分仍以统一评测回报为准。