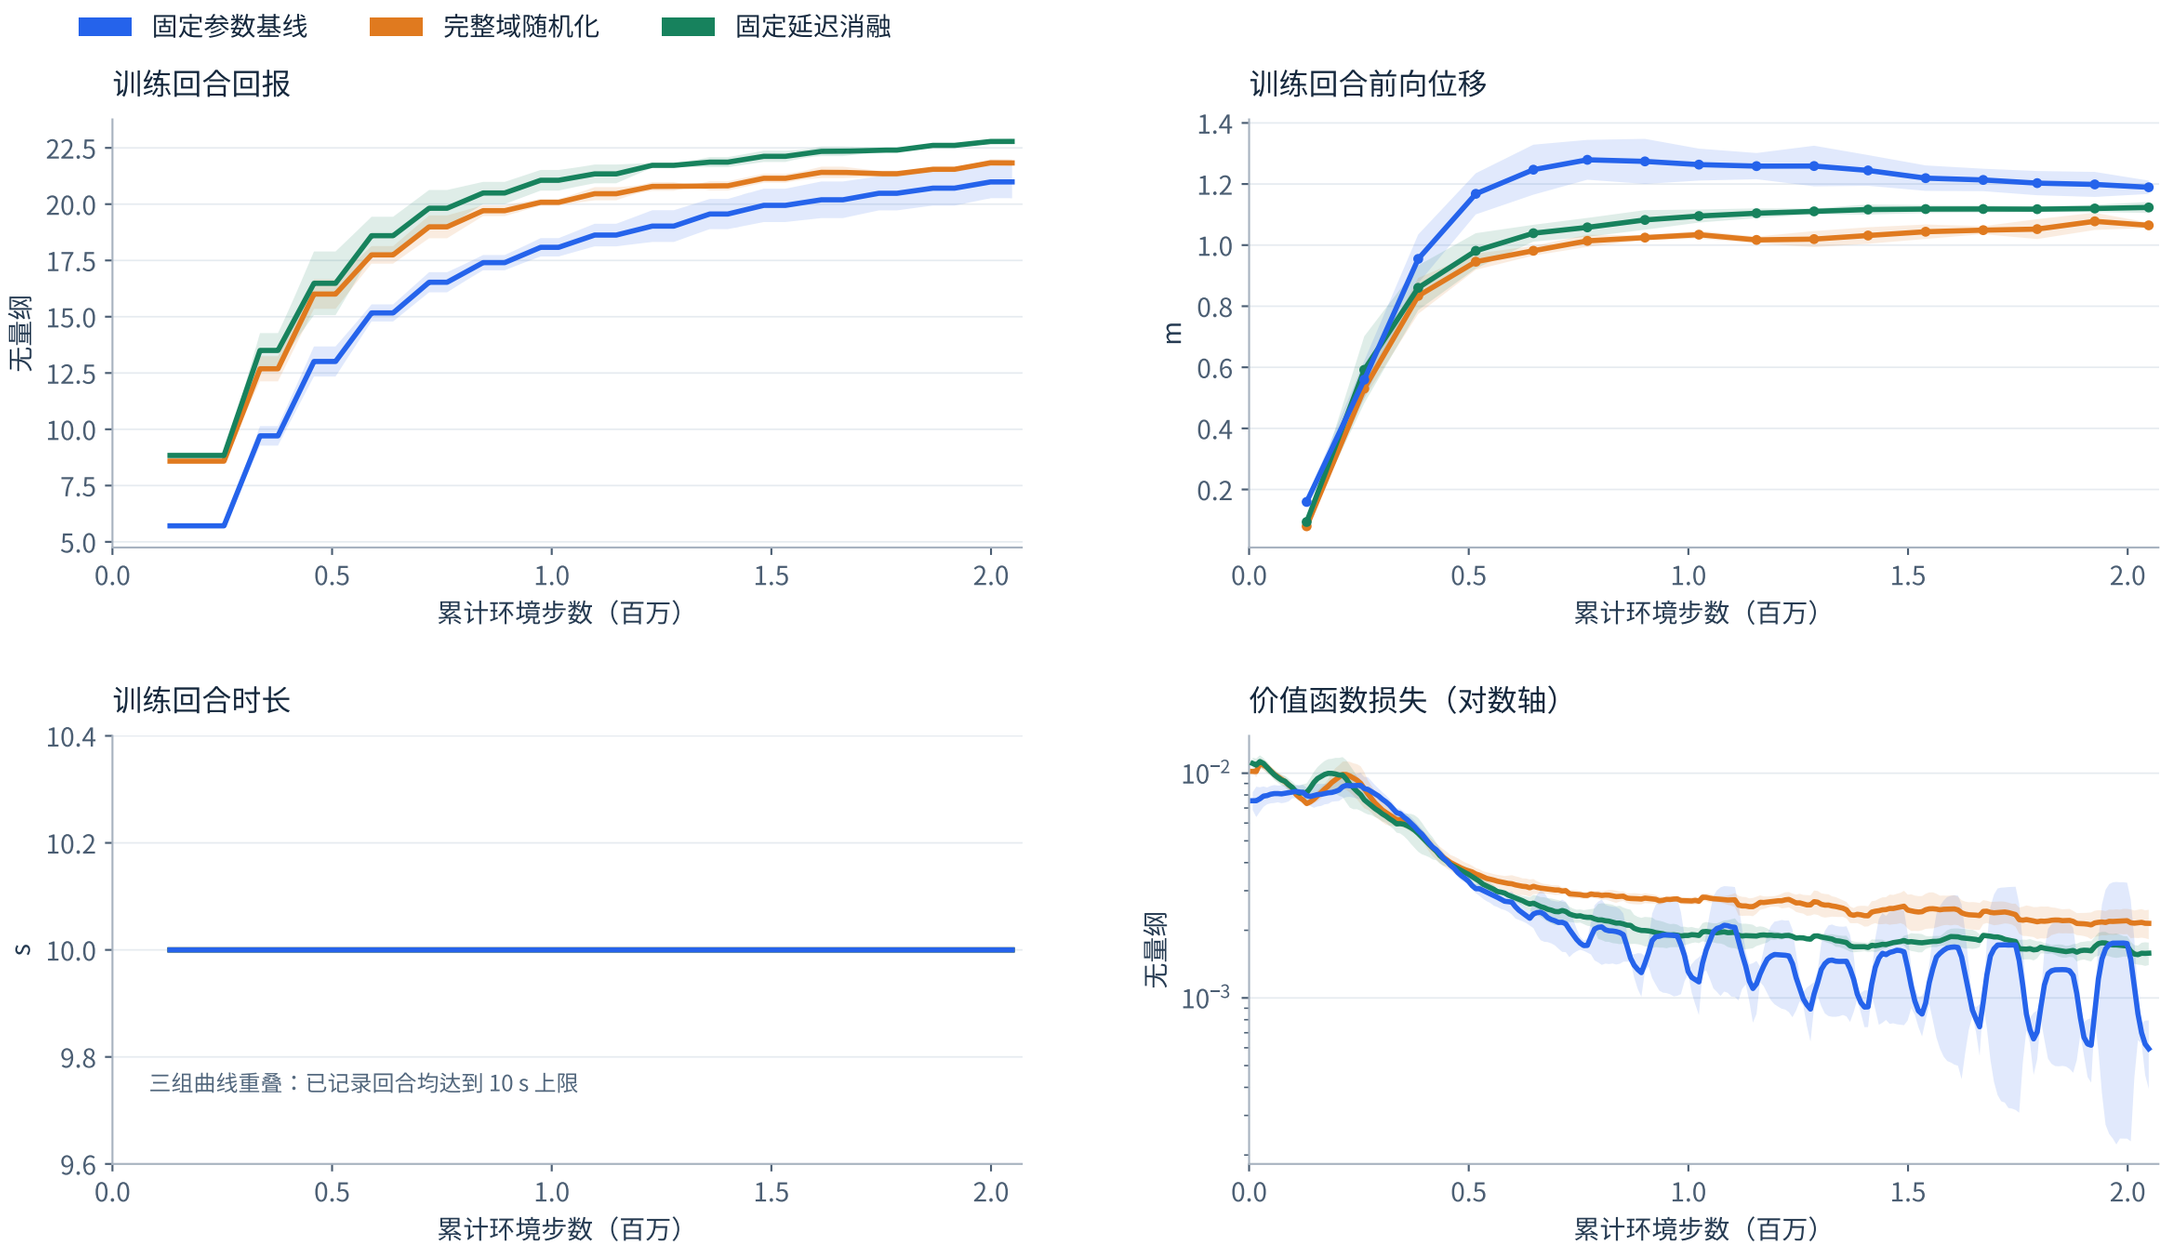
01 训练过程：同等预算下的学习曲线

每个策略 2.048M 环境步 · 250 次更新 · 256 个并行环境 · 每组 3 个训练种子



各种子先取过去 10 个更新内已有值的均值，再计算 3 种子均值 ± 样本标准差（阴影）。位移仅在 16 个回合结束更新点有记录。
三组训练物理分布不同；训练回报与价值损失不作为同条件性能排名。前 15 次更新尚无完整回合；缺失值不补零。