Sesame PPO：训练曲线与方法对比

SESAME · PPO 行走实验 | 2026-11-03

主要结果：随机动力学下速度跟踪更准，同时存在标称性能取舍。

−46.0%

随机条件 RMSE / 相对原 PPO

−10.2%

随机条件 RMSE / 相对固定时延

+28.6%

标称条件 RMSE / 相对原 PPO

前向速度 RMSE（m/s，越低越好）：均值 ± 训练种子样本标准差

方法	标称条件	随机条件
原 PPO 基线	0.04836 ± 0.01141	0.06943 ± 0.00556
完整域随机化	0.06217 ± 0.00300	0.03748 ± 0.00172
固定时延 DR	0.10037 ± 0.00614	0.04172 ± 0.00238

实验规模

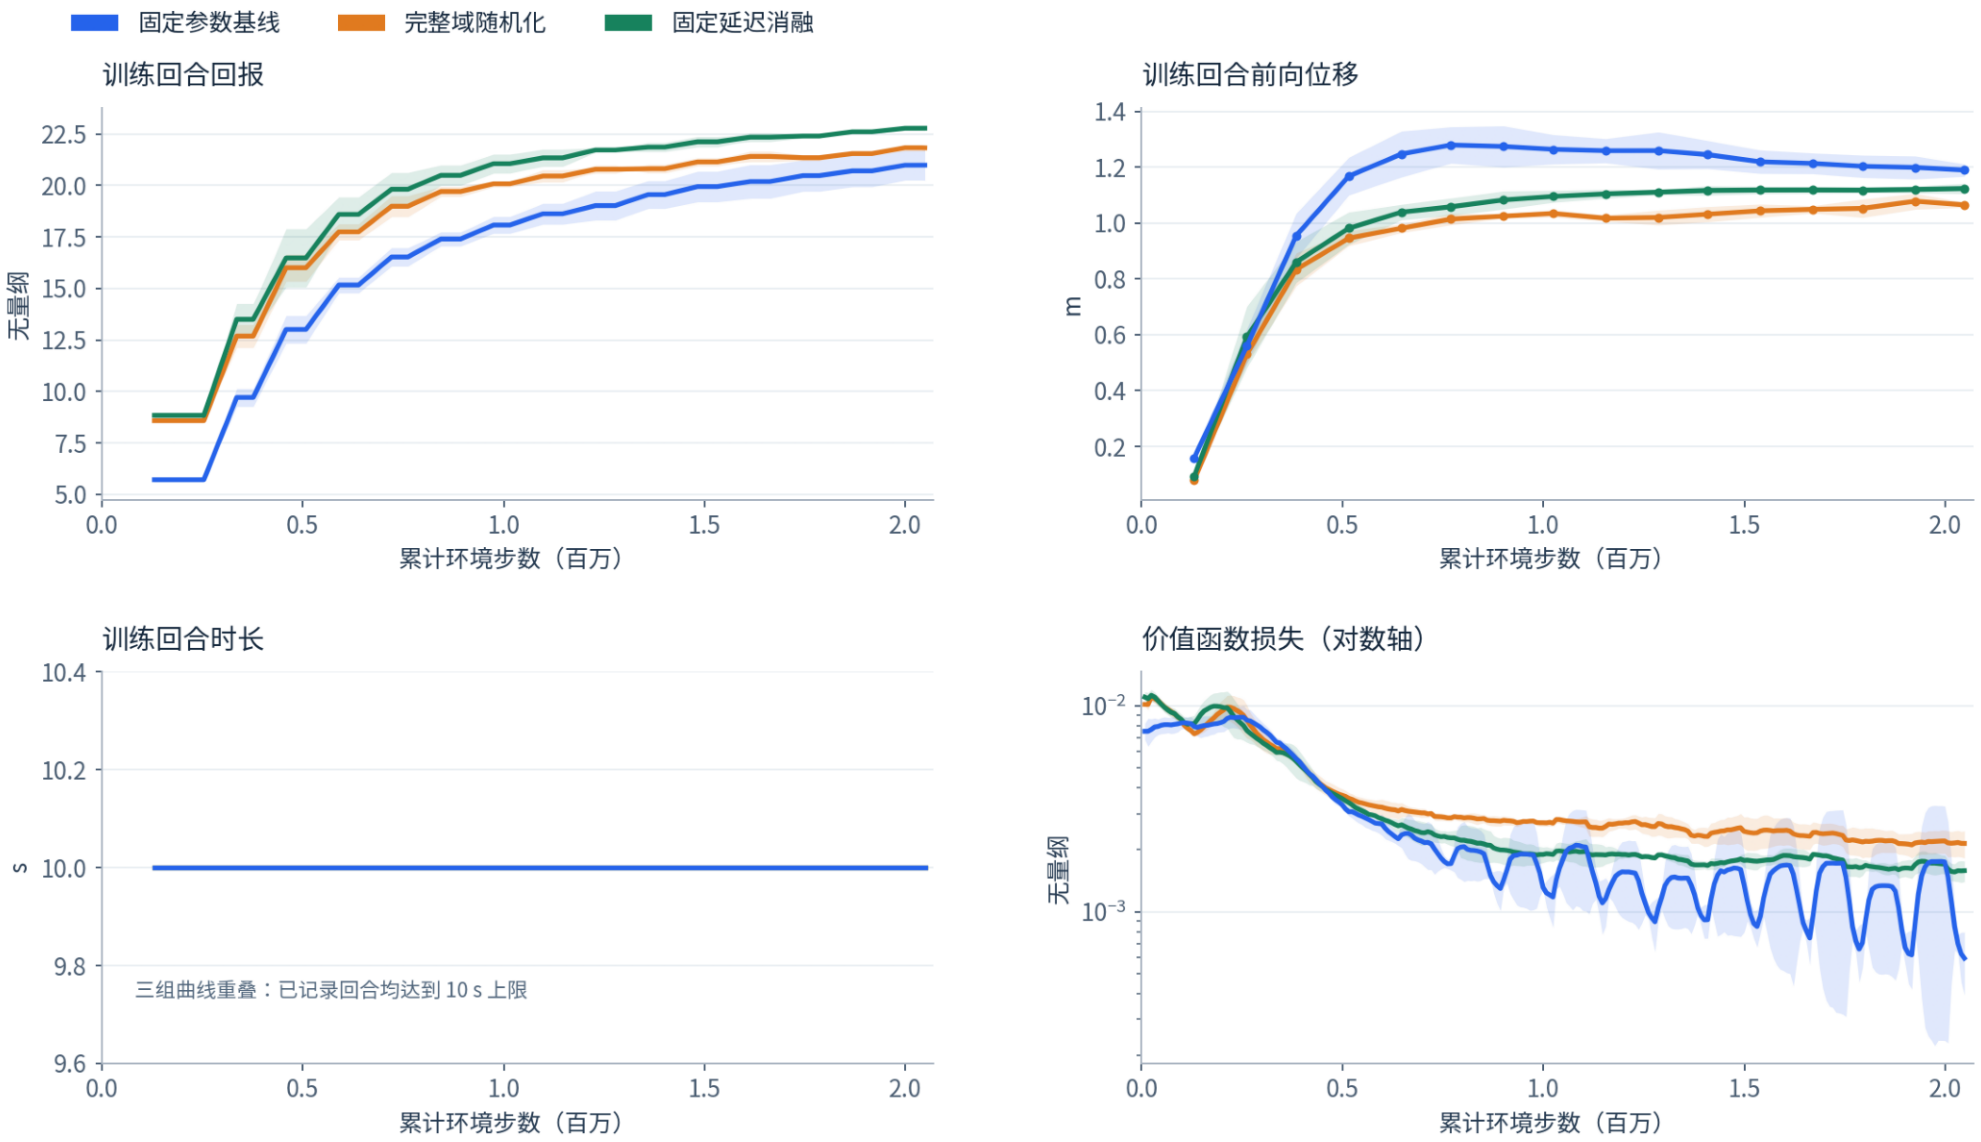
3 组 × 3 个训练种子；每策略 250 次更新 / 2.048 百万环境步。
统一评测 2 个条件、每策略每条件 128 回合，共 2304 回合。

结论边界

未证明整体减少抖动；全部评测零跌倒，无法比较跌倒率改善。
结果限于本地参考仿真和训练参数范围内，不代表官方成绩或实机性能。

01 训练过程：同等预算下的学习曲线

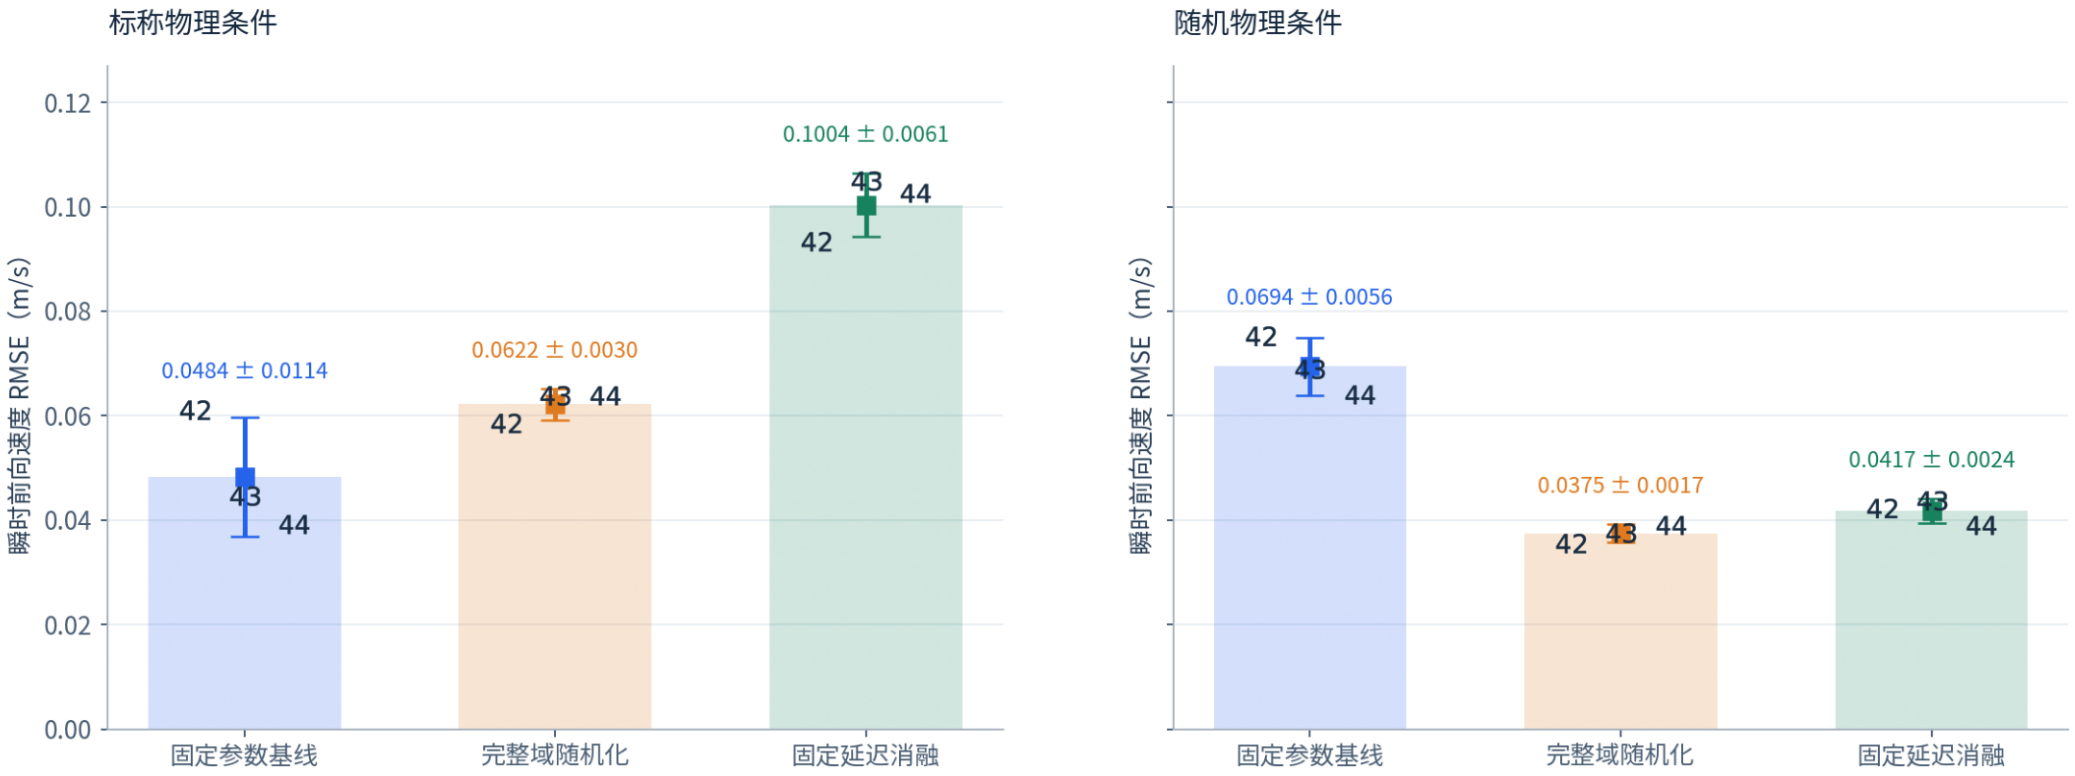
每个策略 2.048M 环境步 · 250 次更新 · 256 个并行环境 · 每组 3 个训练种子



各种子先取过去 10 个更新内已有值的均值，再计算 3 种子均值 ± 样本标准差（阴影）。位移仅在 16 个回合结束更新点有记录。
三组训练物理分布不同；训练回报与价值损失不作为同条件性能排名。前 15 次更新尚无完整回合；缺失值不补零。

02 主要指标：瞬时前向速度跟踪误差

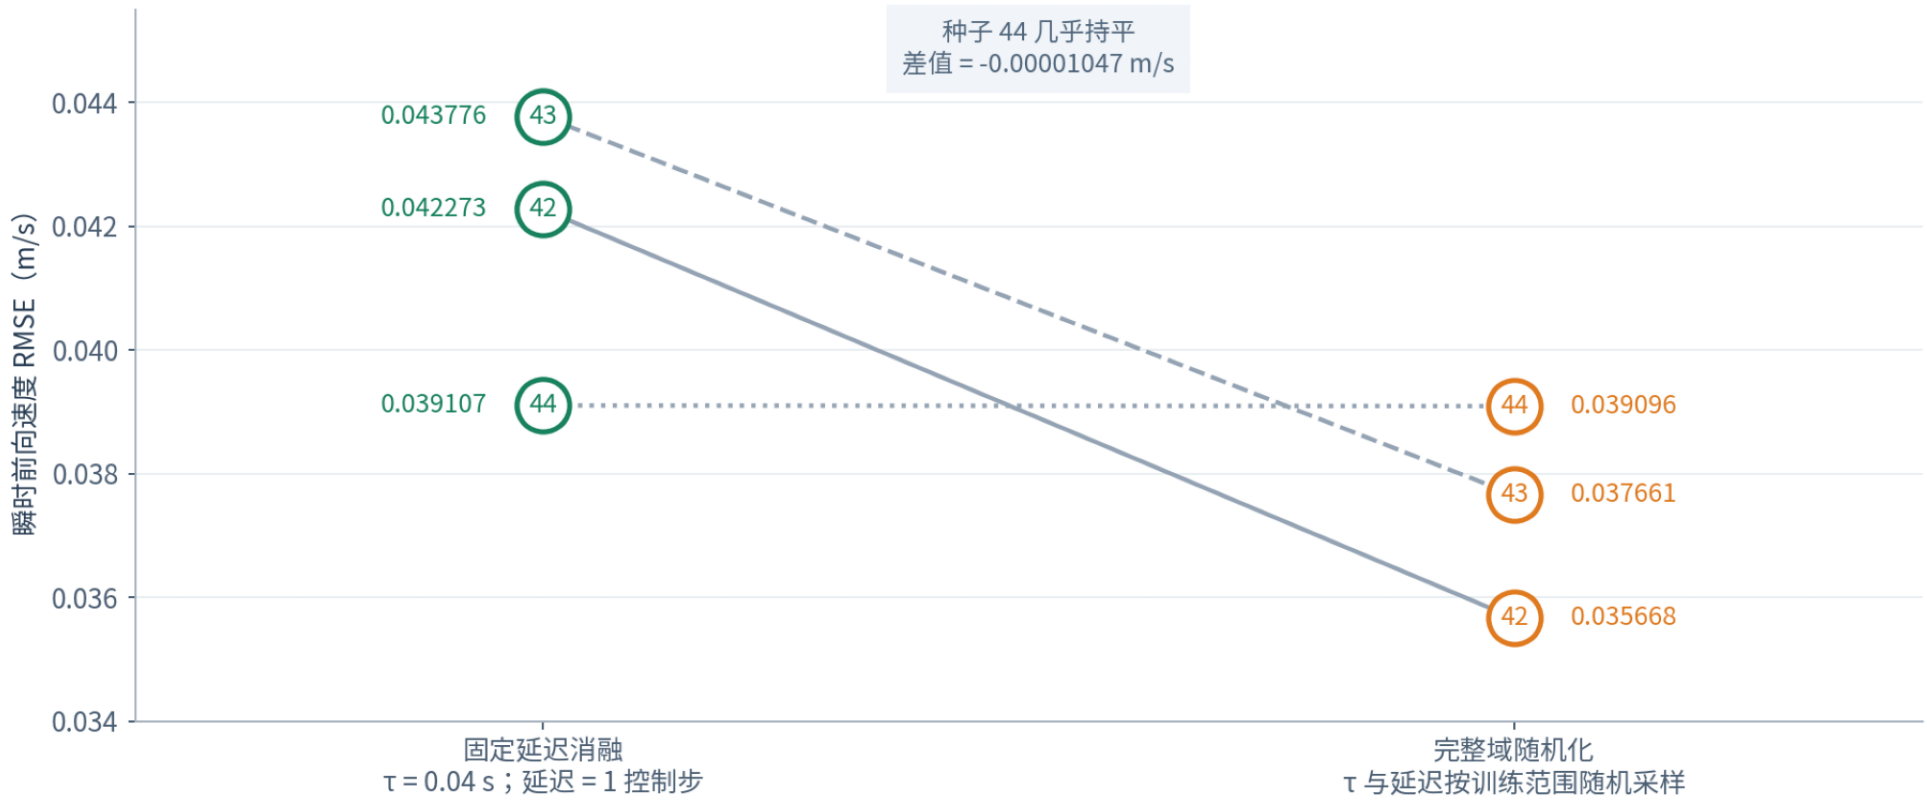
相同评测初始状态与物理参数 · 目标世界 x 速度 0.10 m/s · RMSE 越低越好



方块与误差线：3 个训练种子的均值 ± 样本标准差；数字 42 / 43 / 44：各训练种子结果（每个点平均 128 回合）。
共 18 个策略×条件组合、2304 回合，记录跌倒 0 次。随机条件在训练参数范围内；误差线不是置信区间。

03 延迟消融：同训练种子配对比较

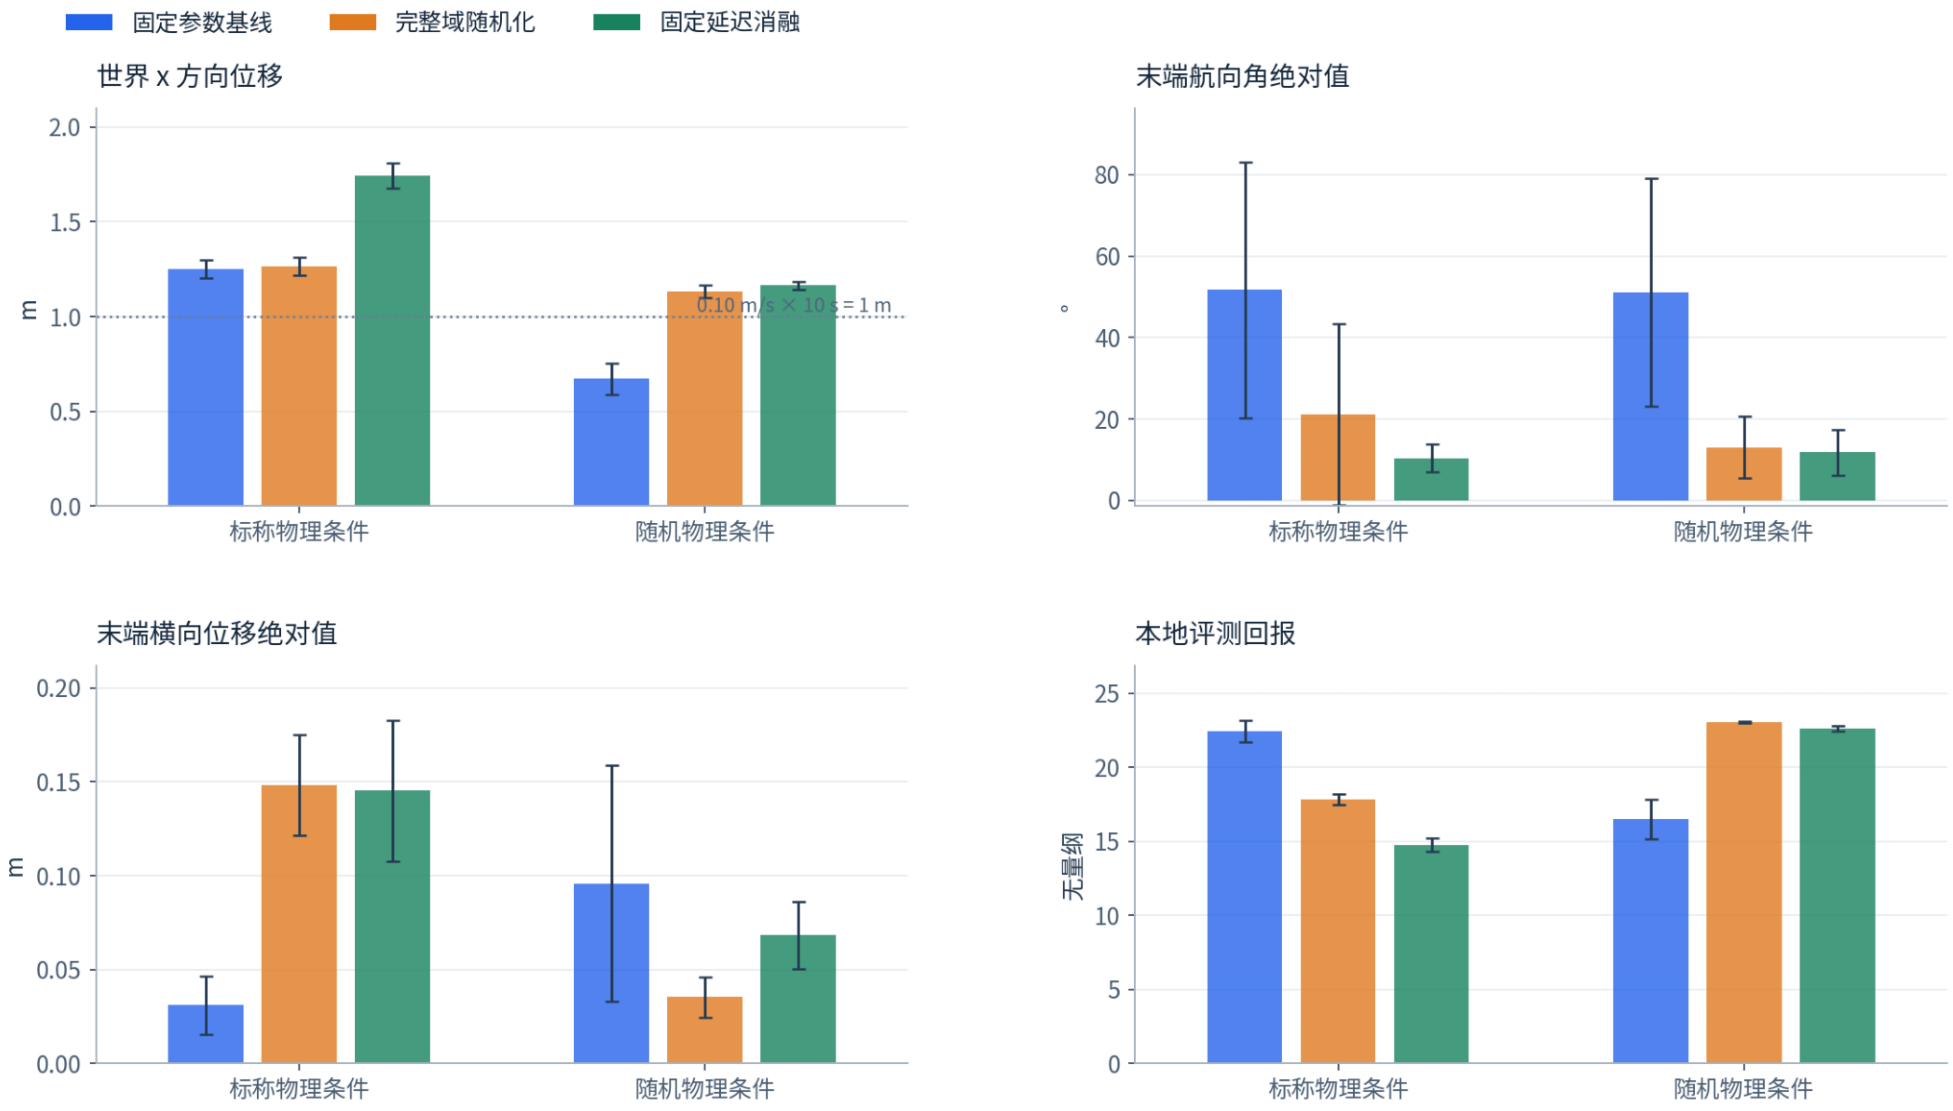
统一随机物理评测 · 仅比较固定中点响应/延迟与完整随机化 · RMSE 越低越好



每条线连接同编号训练种子；每个端点平均 128 个配对评测回合。除响应时间常数与命令延迟外，其他训练随机化设置保持一致。
种子 42、43 有更明显改善，种子 44 近乎持平；独立训练样本仅 n = 3，不据此宣称统计显著性。

04 运动表现：位移、方向与本地回报

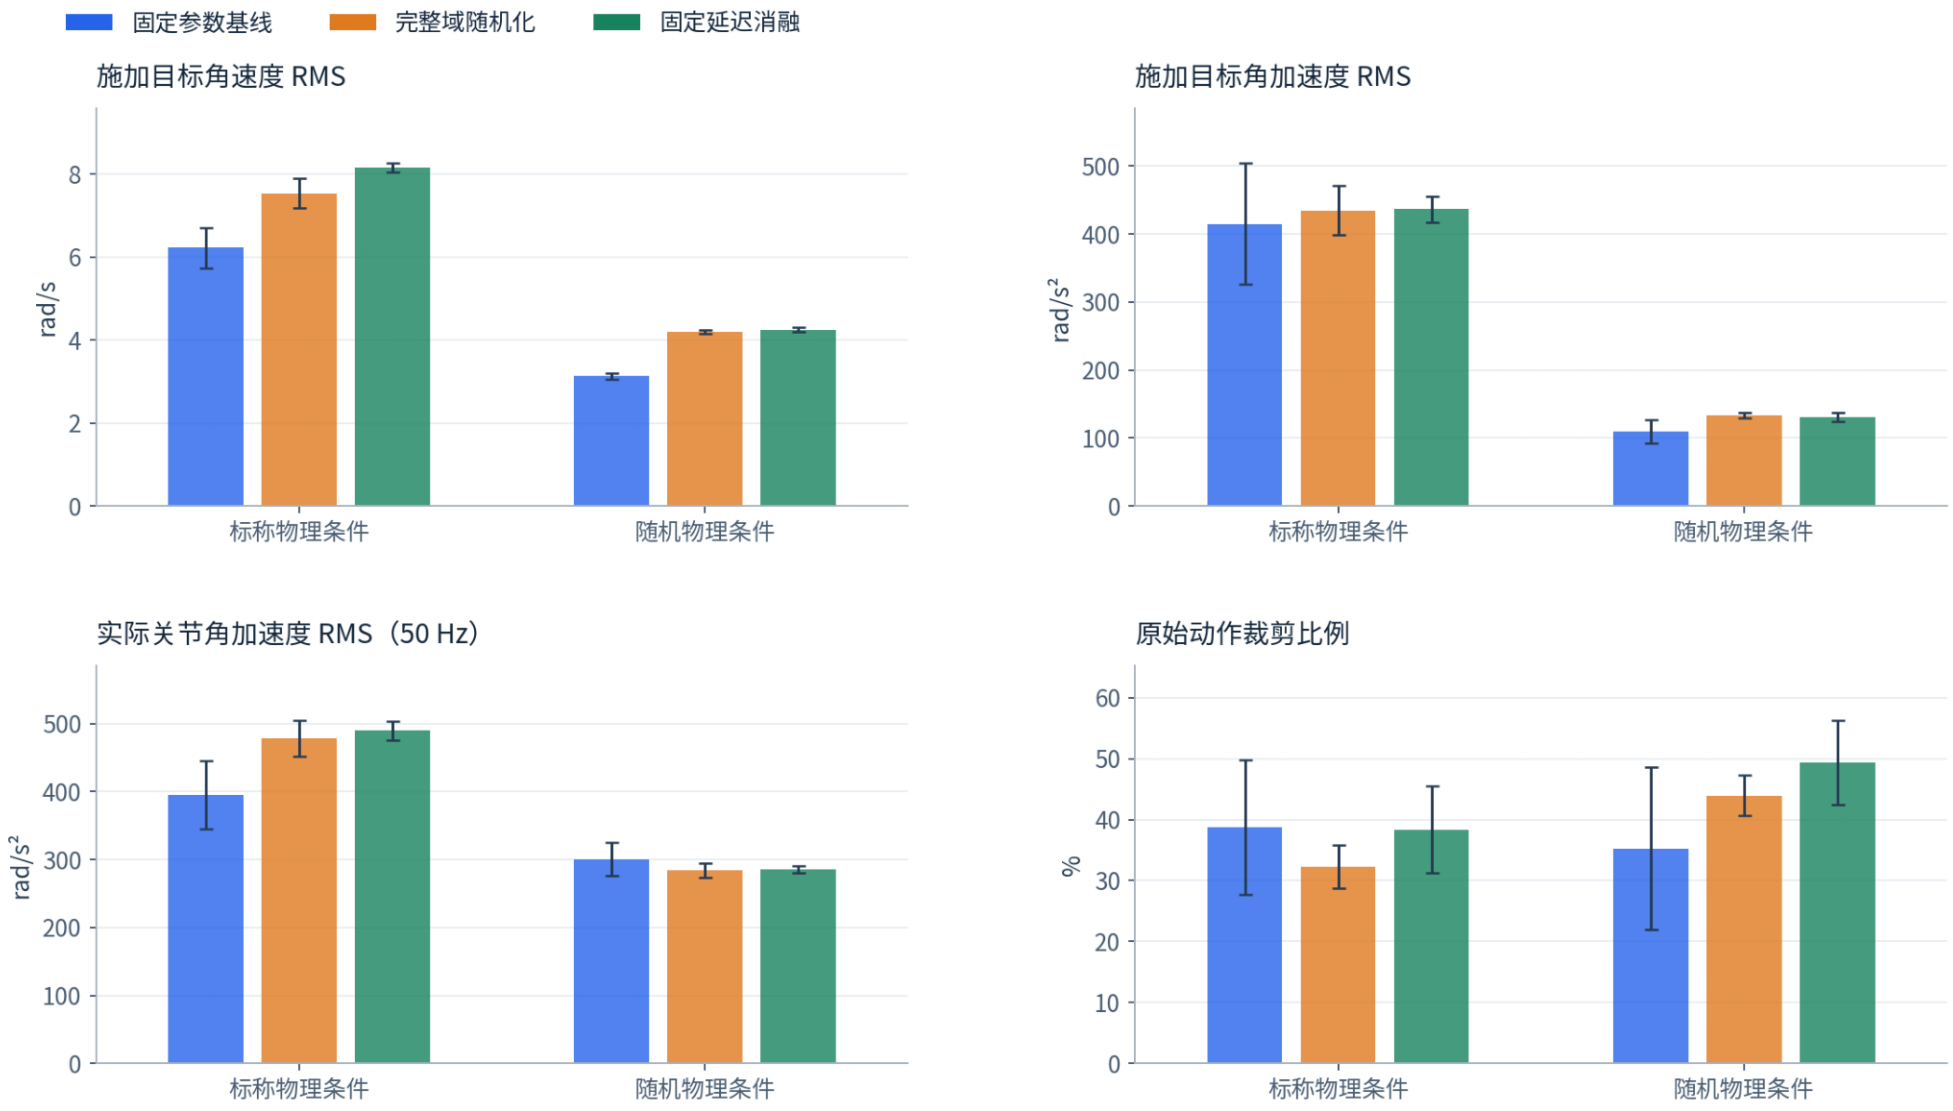
两个共同评测条件 · 柱高为 3 种子均值 · 误差线为种子间样本标准差



更远的位移不一定更接近 0.10 m/s 目标；航向与横向位移均为相对于世界坐标的末端绝对值。
方向相关奖励未修改，不能把速度跟踪改善等同于完全消除侧行。本地回报不代表官方课程分数；共 2304 回合记录跌倒 0 次。

05 平滑性诊断：控制目标与关节响应

全部差分指标按 50 Hz 控制频率统计 · 均值 ± 3 种子样本标准差



目标角变化描述施加命令；实际关节角加速度由关节速度在 50 Hz 采样下差分，不能代表 500 Hz 物理峰值、功率或“抖动频率”。
原始动作裁剪比例在包装器限幅前统计；平滑指标需结合跟踪误差解读。全部 2304 回合记录跌倒 0 次。

实验设置与统计口径

SESAME · PPO 行走实验 | 2026-11-03

任务与三组方法

平坦硬地，目标世界 x 速度 0.10 m/s，10 秒/回合，8 个动作维度；控制 50 Hz，物理步长 0.002 s。三组使用相同 PPO、网络、奖励与预算。

组别	训练设置
原 PPO 基线	原固定物理参数、原初始化和控制器
完整域随机化	物理参数、执行器响应/延迟和初态随机化
固定时延 DR	其余同完整 DR；响应 τ=0.04 s，指令延迟=0.02 s

PPO 与训练预算

256 环境 × 32 步 rollout；250 次更新；种子 42/43/44。网络 128–128–64（ELU），学习率 0.0003（自适应 KL=0.01），clip=0.2，γ=0.99，λ=0.95；5 epochs、4 minibatches，熵系数 0.005。原 PPO 与完整 DR 的种子 42 复用既有等预算模型，其余 7 个新训练。

统一评测与误差条

全部策略使用同一环境，以最终检查点的确定性动作评测。测试种子 3042/4042，各取 64 回合；初态及实际物理参数严格配对。先计算每回合的 500 步瞬时速度 RMSE，再平均 128 回合，最后汇总 3 个训练种子的均值 ± 样本标准差；误差条不是置信区间。

标称条件恢复原控制器零附加滞后/延迟；随机测试使用训练参数范围内的新种子。

如何解读与使用这些结果

SESAME · PPO 行走实验 | 2026-11-03

训练曲线说明学习进展，统一测试决定性能比较

三组在前100次更新（约0.819百万环境转移）提升明显，150次更新后增益放缓；200至250次更新仍有提升。本图说明学习进展，不能证明达到最优策略或给出严格收敛时间。 末 10 次更新的回报见下表；训练回报已包含最近 100 个已完成回合平均，再作 10 次更新平滑。

方法	末 10 次更新的训练回报
原 PPO 基线	20.988 ± 0.729
完整域随机化	21.831 ± 0.151
固定时延 DR	22.786 ± 0.115

平滑性指标：50 Hz 采样的运动代理量

目标变化率 = RMS(Δq_target/0.02)，目标加速度 = RMS(Δ^2q_target/0.02^2)；实际关节加速度 = RMS(Δv_joint/0.02)，v_joint 为关节角速度。目标为执行器最终施加目标，差分排除自动重置跳变。指标包含正常步态，不是抖动百分比、高频功率或 jerk；动作限幅比例单独报告。

实验能支持的结论

完整 DR 对随机条件速度跟踪的改善在 3 个种子方向一致；相对固定时延组的额外收益主要来自种子 42/43，种子 44 近乎持平。基线与完整 DR 比较包含初态和平均执行器动力学变化，不能归因于单一因素。仅 3 个训练种子，未宣称统计显著性或普遍优势。

附件

5 张 PNG 与矢量 PDF、4 份中文 CSV、HTML 报告、统计/协议 JSON 及 10 秒三组对照视频。视频仅用于演示，不能代替多种子统计。